

# PROJECT ĐỒ ÁN HỌC PHẦN

DATA ENGINEER K20

## Xây dựng nền tảng phân tích giao dịch AML trên AWS

Học viên: Trương Văn Hiển



## 1. Tóm tắt nội dung

Ngân hàng/đơn vị thanh toán cần theo dõi hàng chục triệu giao dịch nhưng nhấn AML rất hiếm. Nếu tiếp tục xử lý thủ công bằng file lớn, dữ liệu khó kiểm soát phiên bản, truy vấn chậm và kết quả phân tích khó tái lập. Business case đề xuất một data lake serverless cơ bản trên AWS: S3 lưu dữ liệu theo vùng, Glue quản lý metadata và biến đổi bằng giao diện Visual ETL, Athena truy vấn SQL, Power BI tiêu thụ dữ liệu curated.

| Mục tiêu                               | Giá trị kỳ                                                  |
|----------------------------------------|-------------------------------------------------------------|
| Một nguồn dữ liệu phân tích dùng chung | Giảm phụ thuộc vào file local và đường dẫn cá nhân          |
| Tách raw và curated                    | Bảo toàn nguồn gốc, tăng khả năng kiểm toán và tái xử lý    |
| Chuẩn hóa metadata                     | Glue Data Catalog giúp Athena và BI đọc cùng một định nghĩa |
| Tối ưu truy vấn                        | Parquet + partition giảm lượng dữ liệu Athena phải quét     |
| Business insight                       | Ưu tiên giám sát ACH, cross-bank và nhóm pattern nổi bật    |

## 2. Bài toán kinh doanh

### 2.1. Bối cảnh

Tập dữ liệu mô phỏng hoạt động giao dịch ngân hàng với thông tin tài khoản, ngân hàng nguồn/đích, loại thanh toán, loại tiền và nhãn Is Laundering.

Đội vận hành/risk cần nhìn nhanh tổng lượng giao dịch, tỷ lệ AML, kênh rủi ro và các pattern đáng chú ý.

### 2.2. Problem statement

- Quy mô 31.9 triệu dòng làm Excel và thao tác file thủ công không còn phù hợp
- Dữ liệu nhãn AML cực hiếm (0.1104%), nên chỉ nhìn tổng số có thể che khuất rủi ro
- Dữ liệu tiền tệ khác nhau không thể cộng trực tiếp nếu chưa quy đổi FX
- Dữ liệu theo ngày có dấu hiệu giảm bất thường sau 16/09; phải kiểm tra completeness trước khi kết luận kinh doanh
- Các bảng nguồn và logic KPI cần được chuẩn hóa để báo cáo có thể tái lập

### 2.3. Câu hỏi business

- Kênh thanh toán nào tập trung nhiều giao dịch AML nhất?
- Giao dịch nội bộ hay liên ngân hàng chiếm tỷ trọng cao?
- Những pattern rửa tiền nào cần ưu tiên điều tra?
- Dữ liệu có đủ và nhất quán để đưa vào dashboard không?
- Làm sao mở rộng pipeline mà không phải vận hành server cố định?

### 3. Phạm vi và stakeholder

| Đối tượng            | Nhu cầu                                | Sản phẩm dữ liệu               |
|----------------------|----------------------------------------|--------------------------------|
| Risk / AML analyst   | Khoanh vùng kênh và pattern rủi ro     | KPI, drill-down, bảng chi tiết |
| Business / quản lý   | Theo dõi xu hướng và ưu tiên nguồn lực | Dashboard tổng quan            |
| Data Engineer        | Ingest, chất lượng, metadata, vận hành | Pipeline và data contracts     |
| Auditor / compliance | Truy vết nguồn và logic biến đổi       | Raw immutable, catalog, log    |

Project em làm không phải hệ thống phát hiện gian lận thời gian thực, không huấn luyện mô hình Machine Learning và không đưa ra kết luận pháp lý về một tài khoản. Nhãn AML dùng cho phân tích mô phỏng.

### 4. Dữ liệu nguồn và data contract

| Dataset      | Vai trò                 | Grain / khóa                 | Quy mô     |
|--------------|-------------------------|------------------------------|------------|
| Transactions | Sự kiện giao dịch       | 1 dòng / giao dịch           | 31,898,238 |
| Accounts     | Master tài khoản        | 1 dòng / tài khoản           | 2,087,786  |
| Patterns     | Giao dịch thuộc pattern | 1 dòng / pattern-transaction | 22,743     |

Kỳ dữ liệu quan sát: 01/09/2022 đến 28/09/2022


Có 122,333 ngân hàng trong master

Kiểm tra tham chiếu hiện tại cho thấy không có active account bị thiếu trong master

Quy tắc dữ liệu tối thiểu:

- Khóa giao dịch phải có mặt và không trùng trong grain đã chọn
- Ngày/giờ phải parse được và nằm trong cửa sổ dữ liệu kỳ vọng
- Amount > 0, currency phải thuộc danh mục hợp lệ
- Is Laundering chỉ nhận 0/1, giá trị null được đẩy vào quarantine
- Tài khoản nguồn/đích phải đối soát với account master hoặc được gắn cờ orphan

## 5. Insight business



Hình 1. Dashboard tổng quan hiện có của project

| Insight đã kiểm chứng       | Số liệu                                 | Hàm ý business                                                           |
|-----------------------------|-----------------------------------------|--------------------------------------------------------------------------|
| AML là rare event           | $35,230 / 31,898,238 = 0.1104\%$        | Không dùng accuracy đơn thuần<br>Ưu tiên precision/recall khi mở rộng ML |
| ACH tập trung AML           | 12.13% volume nhưng 87.27% AML          | Ưu tiên rule, điều tra<br>và sampling cho ACH                            |
| ACH có mật độ AML cao       | 0.7948%, $\approx 7.20\times$ mức chung | Đặt ngưỡng/cảnh báo theo kênh thay<br>vì một ngưỡng toàn cục             |
| Cross-bank chiếm ưu thế     | $29,092,624 = 91.20\%$                  | Tập trung lineage ngân hàng<br>nguồn–đích và network view                |
| Self-transfer đáng theo dõi | $2,561,860 = 8.03\%$                    | Xây rule riêng cho vòng<br>lặp/luân chuyển cùng chủ thể                  |
| Cross-currency hiện hữu     | $485,144 = 1.52\%$                      | Không tổng hợp amount<br>khi chưa có bảng FX                             |

## 5.1. Kênh thanh toán ACH



Hình 2. So sánh volume và tỷ lệ AML theo payment format

ACH là điểm nóng rõ nhất trong dữ liệu: tỷ trọng volume không lớn nhất nhưng gom phần lớn giao dịch AML.

Đây là một insight có thể hành động: đội risk ưu tiên kiểm tra rule, danh sách tài khoản/đối tác và chuỗi giao dịch ACH trước.


## 5.2 Pattern rửa tiền



Hình 3. Phân bố pattern và số attempt trong tập pattern

Ba pattern GATHER-SCATTER, SCATTER-GATHER và STACK chiếm khoảng 53.92% tổng pattern transactions

## 6. Chất lượng dữ liệu và cách tránh insight sai



Hình 4. Volume giao dịch theo ngày cho thấy thay đổi mạnh sau 16/09


| Rủi ro dữ liệu       | Cách kiểm soát trong pipeline                                                     |
|----------------------|-----------------------------------------------------------------------------------|
| Sụt volume sau 16/09 | Reconciliation theo ngày<br>So sánh số dòng và min/max timestamp với nguồn        |
| Đa tiền tệ           | Giữ amount gốc + currency<br>Chỉ tạo amount_base khi có FX rate và effective date |
| Rare label           | Báo cả count và rate<br>Tránh biểu đồ làm biến mất nhóm AML                       |
| Schema drift         | Crawler/catalog + bước kiểm tra kiểu dữ liệu<br>Cảnh báo cột mới/mất              |
| Duplicate/orphan     | Deduplicate theo business key<br>Kiểm tra foreign key logic và quarantine         |

## 7. Kiến trúc hiện tại và mục tiêu chuyển đổi

| Hiện tại (đã làm)                                        | Mục tiêu AWS (PoC)                                                                                   |
|----------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| CSV local → ETL SQL/Python<br>→ PostgreSQL DW → Power BI | CSV → S3 raw → Glue Catalog/Crawler<br>→ Glue Visual ETL → S3 curated Parquet<br>→ Athena → Power BI |
| Phù hợp phát triển và học tập                            | Tách storage/compute, serverless,<br>metadata dùng chung                                             |
| Đường dẫn và tài nguyên gắn máy cá nhân                  | Dữ liệu tập trung, có zone và khả năng audit                                                         |

Không sử dụng SSIS. Ở local, Python/SQL đóng vai trò ETL, PostgreSQL đóng vai trò data warehouse. Ở kiến trúc AWS, Glue Visual ETL thay phần orchestration/transformation cơ bản, S3 làm data lake và Athena làm query engine serverless.

## 8. Kiến trúc AWS



Hình 5. Kiến trúc cloud AWS

| Tầng          | Dịch vụ                            | Trách nhiệm Data Engineer                                 |
|---------------|------------------------------------|-----------------------------------------------------------|
| Landing / Raw | Amazon S3                          | Nhận file, giữ nguyên nguồn, phân vùng theo dataset/ngày  |
| Metadata      | AWS Glue Data Catalog + Crawler    | Phát hiện schema, quản lý table definition                |
| Transform     | AWS Glue Visual ETL                | Kéo-thả cast, rename, derive, filter, join và ghi Parquet |
| Serving       | Amazon Athena                      | SQL trên S3 curated, tạo view/KPI và kiểm tra dữ liệu     |
| Consumption   | Power BI                           | Dashboard quản trị và phân tích AML                       |
| Operations    | Glue Workflow/Trigger + CloudWatch | Lập lịch, trạng thái job, log và cảnh báo                 |

## 9. Thiết kế S3 data lake

Bucket PoC đã tạo: ibm-aml-basic-huydungle-20260819 tại ap-southeast-1

Giữ Block Public Access bật. Cấu trúc prefix:

| Prefix                    | Nội dung                  | Chính sách                                    |
|---------------------------|---------------------------|-----------------------------------------------|
| raw/accounts/             | Account master CSV        | Immutable<br>không sửa file tại chỗ           |
| raw/transactions/         | Transaction CSV           | Partition theo ingest_date khi<br>có nhiều kỳ |
| raw/patterns/             | Pattern CSV               | Giữ nguyên nguồn                              |
| curated/dim_account/      | Dimension account Parquet | Snappy, schema ổn định                        |
| curated/fact_transaction/ | Fact transaction Parquet  | Partition txn_date / year-month               |
| temporary/                | Glue temporary files      | Lifecycle xóa sớm                             |
| athena-results/           | Athena query results      | Lifecycle, không public                       |

Parquet là định dạng cột, giúp truy vấn chỉ đọc các cột cần thiết. Partition theo thời gian giúp Athena bỏ qua những thư mục ngoài điều kiện WHERE. Hai kỹ thuật này trực tiếp giảm bytes scanned, thời gian và chi phí truy vấn.

## 10. Glue Data Catalog, Crawler và Visual ETL

### 10.1. Crawler / Catalog

1. Tạo Glue database ibm\_aml\_raw
2. Tạo IAM role tối thiểu cho Glue đọc raw, ghi curated/temporary và ghi log
3. Crawler nhận ba include path riêng: accounts, transactions, patterns
4. Chạy crawler, kiểm tra header, delimiter, data type và table location
5. Chốt schema; crawler không thay thế kiểm thử chất lượng dữ liệu

### 10.2. Visual ETL

| Node kéo-thả             | Xử lý                                                        |
|--------------------------|--------------------------------------------------------------|
| S3 / Data Catalog source | Đọc raw transaction và account                               |
| Change Schema            | Đổi tên cột, cast timestamp/decimal/boolean                  |
| Derived Column           | txn_date, is_cross_bank, is_self_transfer, is_cross_currency |
| Filter / Validate        | Loại/quarantine null key, amount không hợp lệ, timestamp lỗi |
| Join (khi cần)           | Bổ sung thuộc tính account; kiểm tra join cardinality        |
| S3 target                | Ghi Parquet + Snappy vào curated, partition theo thời gian   |



## 11. Mô hình dữ liệu phục vụ phân tích

| Bảng curated               | Grain                        | Thuộc tính chính                                                          |
|----------------------------|------------------------------|---------------------------------------------------------------------------|
| fact_transaction           | 1 dòng / giao dịch           | thời gian, account nguồn/đích, payment format, amount, currency, AML flag |
| dim_account                | 1 dòng / tài khoản           | account, bank, thuộc tính tài khoản                                       |
| dim_date                   | 1 dòng / ngày                | ngày, tuần, tháng, quý                                                    |
| dim_payment_format         | 1 dòng / kênh                | ACH, cheque, wire...                                                      |
| dim_currency               | 1 dòng / currency            | mã tiền tệ, FX tách riêng nếu bổ sung                                     |
| bridge_pattern_transaction | 1 dòng / pattern-transaction | pattern type, attempt, transaction key                                    |

Star schema giúp KPI nhất quán và tránh join tùy ý trong từng dashboard


Fact giữ amount gốc; chỉ dùng amount\_base cho tổng doanh số khi đã có quy tắc FX được kiểm soát

## 12. Athena và lớp phục vụ BI

Athena dùng Glue Data Catalog để truy vấn trực tiếp dữ liệu curated trên S3 bằng SQL

Tạo các view/CTAS ổn định cho BI thay vì để mỗi báo cáo tự viết logic khác nhau

| KPI / view         | Logic cốt lõi                                       | Mục đích                          |
|--------------------|-----------------------------------------------------|-----------------------------------|
| vw_daily_volume    | COUNT(*) GROUP BY txn_date                          | Theo dõi completeness và xu hướng |
| vw_aml_by_format   | COUNT, SUM(is_laundering), rate theo payment format | Tìm kênh rủi ro                   |
| vw_cross_bank      | SUM(CASE source_bank <> dest_bank)                  | Theo dõi dòng tiền liên ngân hàng |
| vw_pattern_summary | COUNT theo pattern_type/attempt                     | Ưu tiên điều tra pattern          |



Hình 6. Trang phân tích pattern hiện có, khi lên AWS sẽ đọc từ lớp curated/Athena

### 13. Vận hành, bảo mật và kiểm soát chi phí

| Nhóm          | Kiểm soát cơ bản                                                                              |
|---------------|-----------------------------------------------------------------------------------------------|
| IAM           | Least privilege<br>Role riêng cho crawler/job<br>Không dùng access key trong file             |
| S3            | Block Public Access<br>Encryption at rest<br>Prefix permission<br>Lifecycle temporary/results |
| Data quality  | Row count, duplicate, null key, min/max date, AML count, orphan account                       |
| Observability | CloudWatch logs/metrics<br>Cảnh báo job Failed/Timeout<br>Lưu run_id                          |
| Idempotency   | Không append trùn<br>Ghi theo partition/run<br>Có chiến lược overwrite rõ ràng                |
| Cost          | Parquet + partition + SELECT cột cần thiết<br>Xem estimated DPU trước khi chạy Glue           |

Athena tính phí theo lượng dữ liệu quét, Glue ETL tính theo tài nguyên và thời gian chạy. Do đó demo dùng sample nhỏ trước, sau đó mới chạy full 31.9 triệu dòng khi tài khoản và ngân sách cho phép.

## 14. Pipeline vận hành mục tiêu

| Bước         | Input → Output         | Gate kiểm soát                              |
|--------------|------------------------|---------------------------------------------|
| 1. Ingest    | Local/export → S3 raw  | Checksum, file size, naming, ingest_date    |
| 2. Catalog   | S3 raw → Glue tables   | Schema review, header/type/location         |
| 3. Transform | Raw → curated Parquet  | DQ rules, reconciliation, reject path       |
| 4. Serve     | Curated → Athena views | KPI test, partition pruning                 |
| 5. Consume   | Athena → Power BI      | Refresh, semantic definitions, access       |
| 6. Monitor   | Run → logs/metrics     | Status, duration, row count, cost indicator |

Reconciliation tối thiểu:

- raw\_count = curated\_valid\_count + rejected\_count
- AML count trước và sau biến đổi không đổi nếu không có rule loại bỏ nhãn
- min/max timestamp và phân bố theo ngày phù hợp nguồn
- Join account không làm nhân bản fact; kiểm tra row count trước/sau join

## 15. Triển khai

| Giai đoạn      | Kết quả bàn giao                     | Tiêu chí hoàn thành                  |
|----------------|--------------------------------------|--------------------------------------|
| Local baseline | Profile, DW, dashboard               | Đã có; KPI đối soát                  |
| S3 landing     | Bucket +<br>raw/curated/temp/results | File sample upload, không public     |
| Catalog        | DB + crawler + 3 tables              | Schema/location đúng                 |
| Visual ETL     | Job transaction → Parquet            | Run succeeded, DQ/reconciliation đạt |
| Athena         | 4 view KPI                           | Query sample đúng số local           |
| BI/operation   | Dashboard + trigger/log              | Refresh và run history quan sát được |

## 16. Rủi ro, hạn chế và phương án xử lý

| Rủi ro / giới hạn         | Ảnh hưởng                         | Phương án                                                  |
|---------------------------|-----------------------------------|------------------------------------------------------------|
| Account AWS denied access | Không tạo crawler/job             | Kiểm tra IAM/SCP/Lab policy                                |
| File transaction rất lớn  | Upload/job lâu, phát sinh chi phí | Sample trước<br>Multipart/CLI<br>Theo dõi DPU và thời gian |
| Dữ liệu chỉ 28 ngày       | Không đại diện mùa vụ dài hạn     | Không ngoại suy, bổ sung nhiều kỳ                          |
| Nhãn AML mô phỏng         | Không dùng làm quyết định pháp lý | Chỉ dùng cho học tập/analytics                             |
| Thiếu FX rate             | Tổng amount sai nghĩa             | Bổ sung dim_fx_rate theo ngày trước KPI tiền tệ            |
| BI trực tiếp trên raw     | Chậm và logic không nhất quán     | Chỉ publish curated views/dataset                          |

## 17. Kết luận

Giá trị lớn nhất của đề xuất không phải chỉ đưa file lên cloud, mà là biến dữ liệu thành một sản phẩm có vùng lưu trữ rõ ràng, metadata dùng chung, bước chất lượng dữ liệu, logic KPI nhất quán và khả năng quan sát vận hành.

Với phạm vi học tập, S3 + Glue + Athena là đủ để cho em tự nhận thấy đầy đủ tư duy triển khai hệ thống trên Cloud